

TALLINNA TEHNIKAÜLIKOOL

Infotehnoloogia teaduskond

Kristjan Luik 211809IAPM

Metsaraie tuvastamine rakendades visiooni alusmudeleid

Magistritöö

Juhendaja: Juhan-Peep Ernits

PhD

Tallinn 2025

Autorideklaratsioon

Kinnitan, et olen koostanud antud lõputöö iseseisvalt ning seda ei ole kellegi teise poolt varem kaitsmisele esitatud. Kõik töö koostamisel kasutatud teiste autorite tööd, olulised seisukohad, kirjandusallikatest ja mujalt pärlinavat andmed on töös viidatud.

Autor: Kristjan Luik

17.05.2025

Annotatsioon

Metsavarade jätkusuutlikuks majandamiseks on hädavajalik metsaraiete tuvastamise täpsus ja ajakohasus. Traditsioonilised statistilised meetodid Sentinel-2 multispektraalsete piltide töötlemisel on osutunud tõhusaks, kuid kannatavad sageli piiratud ruumilise eraldusvõime tõttu ja vajavad lisaks palju manuaalset tööd. Käesolev uurimus käitleb isejuhitud Vision Transformer'i peaahelat DINOv2 väheste õppeandmete põhist semantilist segmentatsiooni lageraie sündmuste tuvastamiseks.

Esmalt loodi andmestik, mis koosneb 100 lageraie polügoonist ja nende ümbritsevatest metsapiirkondadest. Nende põhjal ehitati programm, mis töötleb ja analüüsib metsateatisi, et luua geomeetrilised maskid, mis eristavad okas- ja lehtpuudega alasid. Lisaks sellele laeb programm alla Sentinel-2 taseme 2A satelliidi pildid, et luua andmestik, mis sisaldab nii lageraie maske kui ka nende ümbritsevaid metsapiirkondi.

Tulemusete hindamiseks võrdleme DINOv2-põhist raamistikku *Random Foresti* ja U-Neti segmentatsioonimudelitega, kasutades peamiste kvaliteedimõõdikutena IoU-d ja F1 skoori. Avatud lõpptulemite analüüs võimaldab hinnata tuvastustäpsuse, märgendamistõhususe ja mudeli robustsuse paranemist erinevates metsakoostistes. Edasistes uuringutes käsitletakse ajarealise analüüsi ja täiustatud pilvekatte maskimise (*masking*) strateegiaid.

Lõputöö on kirjutatud eesti keeles ning sisaldab teksti 24 leheküljel, 5 peatükki, 9 joonist, 2 tabelit.

Abstract

Logging detection using vision foundation models

Monitoring and accurately detecting forest logging activities is essential for sustainable forest management and environmental conservation. Traditional statistical approaches, such as Random Forest models applied to Sentinel-2 imagery, have shown promise but still suffer from limited spatial precision and require extensive manual post-processing. In this thesis, we explore the efficacy of a self-supervised Vision Transformer backbone, DINOv2, for few-shot semantic segmentation of logging events in Sentinel-2 multispectral images.

A smaller dataset comprising 100 clear-cut polygons and their adjacent forest environs was constructed by integrating publicly available metsateatis records from the Estonian Forest Registry with Sentinel-2 Level-2A surface reflectance tiles. Initial geometric masks were refined through manual delineation and K-Means clustering to differentiate coniferous and deciduous strata. The pretrained DINOv2 model was subsequently fine-tuned on this dataset, utilizing the 10 m spatial resolution spectral bands alongside derived vegetation indices to enable pixel-level discrimination of logging areas.

To evaluate performance, we compare the DINOv2-based framework against benchmark Random Forest and U-Net segmentation models, using Intersection over Union (IoU) and F1 score as primary metrics. This open-ended analysis will assess relative improvements in detection accuracy, annotation efficiency, and robustness to varying forest compositions. Further investigation will address temporal sequence incorporation and advanced cloud-masking strategies.

The thesis is in Estonian and contains 24 pages of text, 5 chapters, 9 figures, 2 tables.

Lühendite ja mõistete sõnastik

Ülelennu sagedus	(<i>Revisit time</i>) ajavahemik, mis jäab mingi kindla piirkonna satelliidi divaatluste vahele
Lainepeikkus peaahel	(<i>Band</i>) lainepeikkuste vahemik elektromagnetkiirguse spektris (<i>Backbone</i>) mudeli peamine arhitektuur, mis on eelnevalt treenitud ja millele on lisatud täiendavad kihid, et saavutada soovitud ülesanne
R2	R-ruut (<i>R-squared</i>) regressioonimudeli täpsuse mõõdik, mis näitab mudeli selgitusvõimet andmete variatsioonis
IoU	Ühenduse indeks (<i>Intersection over Union</i>) mõõdik, mis hindab mudeli täpsust, võrreldes ennustatud ja tegelikke tulemusi
F1 skoor	F1 skoor (<i>F1 score</i>) mõõdik, mis ühendab täpsuse ja meeldetuletuse ja annab tasakaalustatud hinnangu mudeli jõudlusele
NDVI	Taimede indeksi (<i>Normalized Difference Vegetation Index</i>) mõõdik, mis hindab taimekatte tihedust ja elujõudlust, arvutatakse punase ja lähedase infrapunase lainepeikkuse vahekorra põhjal

Sisukord

1	Sissejuhatus.....	9
2	Valdkonna ülevaade	11
2.1	Metsandus.....	11
2.2	Copernicus ja EstHub.....	11
2.2.1	Sentinel.....	12
2.2.2	Lainepikkuste spekter	13
2.2.3	Koordinaatsüsteemid ja CRS	13
2.3	Masinõppe meetodite kasutus kaugseires	14
3	Lahendus	16
3.1	Töövahendid.....	16
3.2	Andmestiku loomine	18
3.2.1	Raie piirkonna andmete kogumine.....	18
3.2.2	Raie piirkonna maskide loomine	21
3.3	Alusmudeli ülevaade	21
3.3.1	CLIP ja selle kasutus	22
3.3.2	DINO v2 ja selle kasutus.....	22
3.3.3	SAM v2 ja selle kasutus	24
3.4	Seoste leidmine	25
3.5	Treenimis protsetuurid	30
4	Tulemuste analüüs	31
4.1	Tulemuste võrdlus	31
4.2	Edasiarendus ja täiustamine.....	31
5	Kokkuvõte.....	32
	Kasutatud kirjandus	33
	Lisa 1 – Lihtlitsents lõputöö reproduutseerimiseks ja lõputöö üldsusele kättesaadavaks tegemiseks.....	36

Jooniste loetelu

Joonis 1.	Sateliidi andmete liikumine andmekeskuste vahel	12
Joonis 2.	Näidis ühe lageraie päringust saadud ümbrus.....	19
Joonis 3.	KMeans klasterdamise tulemus, 100 raie ümbrust leht- või okaspuudega ..	20
Joonis 4.	Andmestiku loomise töövoog.....	21
Joonis 5.	Näidis sateliidi pilt	26
Joonis 6.	Raie piirkonna mask sateliidi pildil.....	27
Joonis 7.	Raie piirkonna mask eksperdi poolt korrigeeritud.....	28
Joonis 8.	Segmenteeritud näidis sateliidi pildist.....	29
Joonis 9.	T-SNE kluster analüüs DinoV2 mudeli väljunditest	30

Tabelite loetelu

Tabel 1. Sentinel-2 MSI spektriribad ja nende kasutusvaldkonnad..... 13

Tabel 2. Kasutatud riistvara 18

1 Sissejuhatus

Antud magistritöö põhieesmärgiks on võrrelda masinõppe meetodeid ja tuua välja täpseim mudel, mis suudaks tuvastada metsaraiet satelliidipiltidelt. Mida aeg edasi seda rohkem on riigid hakanud mõistma kui tähtis on metsamajandus, metsade säilitamine ja hoidmine. Tehnoloogia pideva arenguga on hakatud otsima viise kuidas riik või kogukond saaksid paremat ülevaadet suurtest metsaga kaetud aladest. Metsa seireks kasutatakse peamiselt mehitamata õhusõidukeid (Unmanned Aerial Vehicles), maapealseid sensoreid, satelliidipildi töötlust ja vabatahtlike kaasavaid rakendusi (Crowdsourcing Applications) [1].

Praegusel hetkel kasutatakse Eestis mõni aasta tagasi Keskkonnaagentuuri ja Tartu Ülikooli koostöös väljatöötatud statistika mudelite, mis raie tuvastamiseks kasutab suvasalu (Random forest) algoritmi [2] satellidi piltidelt. Selle mudeli esmased tulemused olid paljulubavad, aga peale mõndaaegset kasutamist pole see ikkagi rahuldavaid tulemusi andnud ja mudeli kasutajad on sunnitud siiski manuaalseid viise kasutama.

Euroopa Liidu kaugseireprogrammi Copernicus võimaldab Eesti riigil koguda satelliidi pilte andmekeskusesse Esthub [3]. Lisaks muule infole, mida hallatakse Copernicus-es ja seeläbi ka Esthub-is, on kasutusel informatsioon, mis tuleb erinevatelt Sentineli nime kandvatelt satelliitidelt [4]. Kuna Sentinel-2 on juba 2015. aastast töös olnud, sisaldab laia valikut valgusribasid ning on tiheda korduskülastus sagedusega [5], siis keskendub käesolev magistritöö peamiselt sellele satelliidi tüübile.

Sellest tulenevalt ona üheks alam eesmärgiks luua Python programm, mis hõlbustaks satelliidi piltide allalaadimist ja töötlemist. Peale andmete kogumist on plaan läbi viia tänapäevaste masinõppe mudelite võrdlus raiete tuvastamiseks. Raiet hinnatakse piksl põhise täpsusega üle pildi. Hiljuti on tehtud mitmeid uuringuid selles valdkonnas, kus kasutatakse ka suvasalu, XGBoost ja U-Net'il põhinevaid mudeli arhitektuure [6], [7]. Mõlemas uurimistöös on ka mudelite võrdlus välja toodud, aga need keskenduvad erinevatele suundadele. Esimese puhul ehitatakse mudelid kasutades rohkem pilte läbi aja, et mudel

saaks paremini tuvastada muutust. Teise puhul keskendutakse erinevate lainepekkuste kombineerimisele, et tabada muutusi.

Peale mudelite treenimist samadelt lähteandmetelt on antud magistritöös välja toodud tulemuste mõõtmine. Piksli tasemel täpsuse mõõtmiseks kasutatakse Intersection over Union - kattuvuse hinnang, Dice Coefficient - meetrika mis on põhimõtteliselt segmenteerimise F1 Score [8], [9]. Nende tulemuste abil saab teha võrdluse erinevate tuvastusmudelite vahel, et leida neist täpseim.

Sellest tulenevalt sai antud magistritöö uurimisküsimusteks:

- Kui täpselt on võimalik tuvastada lageraie sündmusi satelliidi piltidel kasutades selleks DinoV2 alus mudelit?
- Kas on võimalik luua automatiseeritud programm, mis suudab allalaadida ja töödelda satelliidi pilte?
- Milline andmekogumik on vajalik, et saavutada kõrge täpsus lageraie sündmuste tuvastamiseks?

2 Valdkonna ülevaade

2.1 Metsandus

Metsad omavad olulist rolli nii ühiskonna igapäevaelus kui ka planeedi heaolus. Alates mööblis kasutatavast puidust kuni paberini, millele kirjutame. Lisaks neile nähtavatele toodetele sisaldavad paljud ravimid, kosmeetika ja pesuvahendid metsadest saadud kõrvalsaadusi. Rohkem kui 1,6 miljardit inimest sõltub metsadest toidu ja kütuse saamisest ning umbes 70 miljonit, sealhulgas paljud põlisrahvad, peavad metsi oma koduks [10]. Metsad varustavad meid hapnikuga, pakuvad varjualust, töökohti, puhist vett ja toitu, olles seega inimkonna ellujäämiseks hä davajalikud. Kuna nii paljude inimeste elu sõltub metsadest, on metsade saatus otseselt seotud ka meie endi tulevikuga. [11]

2.2 Copernicus ja EstHub

Eesti metsade kaugseires on oluline roll Copernicuse programmil ja EstHubi keskusel. Copernicus on üks osa Euroopa kosmoseprogrammist (EUS), mis tegeleb planeedi jälgimisega. Copernicus programmi raames, lisaks maa pealse info kogumisele, on loodud mitmeid satelliite, mis koguvad informatsiooni kosmosest. See info on kõigile kättesaadav tasuta. Selle programmiga seotud satelliite kutsutakse **Sentineliks**. [12]

EstHub on Eesti riiklik satelliitandmete keskus, mis kogub ja integreerib mitmekesiseid georuumilisi andmeid automatiseritud protsesside kaudu. Andmekogumine hõlmab kõrge resolutsiooniga satelliitkaadrite allalaadimist ja standardiseerimist erinevatest allikatest. EstHubi eesmärk on koguda kokku satelliidi andmed mis katavad Eesti territooriumi. [13]



Joonis 1. Sateliidi andmete liikumine andmekeskuste vahel

2.2.1 Sentinel

Kaugseire valdkonnas on vastavalt vajadusele kasutusel erinevatelt satelliitidelt pärinevad andmed. Sentinel-1 on radaripõhine satelliit, mis võimaldab jälgida maapinna vajumist, struktuuride kahjustusi ning looduskatastroofe nagu maavärinad ja maalihked. Samuti on see ideaalne mere- ja Arktika seireks, sealhulgas laevade jälgimiseks ning naftareostuse tuvastamiseks. [14]

Sentinel-2 missioon koosneb kahest identsest satelliidist, Sentinel-2B (käivitatud 2017) ja Sentinel-2C (käivitatud 2024), mis töötavad koos, et pakkuda kõrge eraldusvõimega multispektraalseid pilte Maa pindadest, rannikualadest ja siseveekogudest iga viie päeva järel. Need andmed toetavad rakendusi põllumajanduses, metsanduses ja maakatte klassifitseerimisel. [15]

Sentinel-3 on Euroopa Maa seire satelliitmissioon, mille eesmärk on mõõta merepinna topograafiat, mere ja maa pinnatemperatuure ning ookeani ja maa pinnavärvi suure täpsusega. Neid andmeid kasutatakse ookeani prognoosisüsteemides, keskkonnaseires ja kliimaseires. [16]

Sentinel-5P on esimene Copernicuse missioon, mis on pühendatud atmosfääri seirele. See kannab tipptasemel **Tropomi** instrumenti, mis kaardistab mitmeid gaase nagu lämmastikdioksiid, osoon, formaldehüüd, vä Gäveldioksiid, metaan, vingugaas ja aerosoolid - kõik need mõjutavad meie hingatavat õhku, tervist ja kliimat. [17]

2.2.2 Lainepikkuste spekter

Spektriribad on satelliitandmete analüüsimeisel üliolulised, sest need võimaldavad eristada maapinna erinevaid omadusi, lähtudes elektromagnetilise spektri konkreetsetest lainepikkustest. Näiteks Sentinel-2 MSI instrumendi 13 spektririba hõlmavad nähtavat valgust, lähedast infrapunat ja lühilaine infrapunat, võimaldades detailset maaстиku klassifitseerimist, sealhulgas metsade, veekogude ja muu loodusliku keskkonna eristamist. Iga ribaga seondub kindel lainepikkuse vahemik, mida spetsiifiliste filtrite abil eraldatakse. [18]

Riba	Resolutsioon	Kasutus
B01	$60m px^{-1}$	Aerosool
B02	$10m px^{-1}$	Sinine
B03	$10m px^{-1}$	Roheline
B04	$10m px^{-1}$	Punane
B05	$20m px^{-1}$	Vegetatsiooni klassifitseerimine
B06	$20m px^{-1}$	Vegetatsiooni klassifitseerimine
B07	$20m px^{-1}$	Vegetatsiooni klassifitseerimine
B08	$10m px^{-1}$	Lähiinfrapunariba on hea rannajoonte ja biomassisalduse kaardistamiseks
B8A	$20m px^{-1}$	Kitsam lähedane infrapunane
B09	$60m px^{-1}$	Veeaur tuvastus
B10	$60m px^{-1}$	Pilvede tuvastus
B11	$20m px^{-1}$	Lühilaine infrapunane 1
B12	$20m px^{-1}$	Lühilaine infrapunane 2

Tabel 1. Sentinel-2 MSI spektriribad ja nende kasutusvaldkonnad

2.2.3 Koordinaatsüsteemid ja CRS

Satelliidilt saadud andmete maapinnaga sidumiseks on vaja kasutatada koordinaatsüsteeme ja koordinaatide viite süsteeme (CRS).

Koordinaatsüsteem on meetod, mille abil määratletakse ja kirjeldatakse punktide asukohti maastikul, kasutades koordinaate. Selles kontekstis eristatakse kahte tüüpi: geograafilised koordinaatsüsteemid, mis kasutavad laiuse ja pikkuse väärtsusi, ning projekteeritud koordinaatsüsteemid, mis teisendavad geograafilised koordinaadid lameda kaardi koordinaatideks, kasutades matemaatilisi projektsioone. CRS ehk koordinaatide viite süsteem määratleb reeglid ja parameetrid, mille alusel need koordinaadid seonduvad reaalsele maastikuga. [19]

2.3 Masinõppe meetodite kasutus kaugseires

Käsitletava teemaga seotud, kuid teiste piirkondade põhjal loodud, uurimistööde analüüsimal prooviti välja selgitada, milliseid meetodeid on üldiselt kaugseires kasutatud, sealjuures kas on ehitatud mudeliteid nullist või kasutatud valmis mudeliteid. Samuti oli oluliseks eesmärgiks, välja selgitada, kas nendel juhtudel on kasutatud süvaõpet või mitte. Lisaks sooviti teada saada, mis satelliidi andmeid on varasemalt kasutatud ja kas eri lainepikkuste sidumine on andnud paremaid tulemusi.

Ukraina teadlaste poolt koostatud 2021. aastal välja antud artiklis „Deep Learning for Regular Change Detection in Ukrainian Forest Ecosystem With Sentinel-2“ kasutati Copernicus Sentinel-2 satelliidi pilte, mis sisaldasid kõrge resolutsiooniga (10 m) värv- ja spektrikanaleid, sealhulgas NDVI ja NDMI indekseid, võimaldades jälgida metsamuutusi kuni 5-päevaste intervallidega. Andmekogum loodi käsitsi Kharkivi piirkonnas, kasutades mitut järjestikust pilti ja põhjalikku märgistust, et tagada täpne deforestsatsionipiirkondade kaardistamine. Urijad rakendasid süvaõppe meetodeid, kasutades mitut U-Neti varianti (näiteks UNet-diff, UNet-CH, UNet2D, UNet3D, Siamese U-Netid ja UNet-LSTM), et hinnata nii ajast sõltuvalt kui ka ühekordseid lähenemisviise. Eraldi rõhutati piltidevahelise erinevuse kasutamise eeliseid, mis parandas segmentatsioonitulemusi ning tõstis Dice ja F1 skoore. Lisaks ilmnesid uuringus olulised nüansid, nagu pilvekatte, hooajaliste muutustega ning geograafiliste lähknevuste mõju, mis nõudsid täiendavat andmete eeltöötlust. Huvitav on, et kuigi kõik mudelid näitasid potentsiaali, saavutavad UNet-diff ja UNet-CH kõige kõrgema täpsuse, pakkudes sealäbi töenduspõhiseid lahendusi metsakatteta ala muutustega regulaarseks jälgimiseks. [6]

Uus-Meremaal läbi viidud ja 2024. aastal välja antud uurimistöös „Developing a forest description from remote sensing: Insights from New Zealand“ kasutati kõrglahutusega lennufotosid ning regionaalseid ALS-andmeid radiata männi metsade täpseks kaardistamiseks Uus-Meremaal. Analüüs tugines sügavõppepõhisel semantilise segmentatsiooni mudelil, mis kasutab DeepLabv3+ arhitektuuri koos ResNext-101 peahelana (backbone), saavutades IoU väärtsused 0,94, täpsuse 0,96 ja meeldetuletuse 0,98. Keeruliseks osutus aga noorte istikute tuvastamine, mille puhul *juvenile* klass (noored istutatud metsapiirkonnad) liideti *radiata* (küpsemad männi alad) klassiga. Lisaks sügavõppemudelile kasutati mitmemuutujalisi regressioonimudeliteid metsade keskmise kõrguse, kogumahte ja vanuse

hindamiseks, saavutades kõrged R2 väärtsused. [20]

3 Lahendus

3.1 Töövahendid

Python

Python on üldotstarbeline programmeerimiskeel, mida kasutatakse laialdaselt andmeteaduse, masinõppe ja ruumiandmete analüüsiga ülesanneteks oma lihtsuse ja mitmekülgse tõttu. Käesolevas töös kasutatakse Pythonit andmete töötlemiseks, mudelite treenimiseks ja tulemuste analüüsimiseks.

Jupyter Notebookid

Jupyter Notebookid pakuvad interaktiivset keskkonda, kus saab koodi kirjutada, käivitada ja dokumenteerida ühes kohas. Need võimaldavad dünaamilist andmeanalüüsia ja tulemuste visuaalset esitlust, muutes uurimisprotsessi läbipaistvaks ja korduvaks. Käesolevas töös kasutatakse Jupyter Notebooke peamiselt katsetuste tegemiseks ja tulemuste visualiseerimiseks.

Pandas

Pandas on andmetööluse teek, mis pakub paindlikke ja efektiivseid andmestruktuure tabelipõhise andmetööluse jaoks. See lihtsustab andmete puastamist, analüüsia ja manipuleerimist. Käesolevas töös kasutatakse Pandast andmete lugemiseks, töötlemiseks ja analüüsimiseks.

GeoPandas

GeoPandas laiendab Pandase võimalusi, lisades tuge georuumilistele andmetele. See võimaldab lugeda, analüüsida ja visualiseerida ruumiandmeid ning teostada geomeetrisi operatsioone nagu lõikumine ja ühendamine.

Rasterio

Rasterio on Pythoni teek, mis keskendub rasterandmete lugemisele ja töötlemisele tuginedes GDAL-ile. See võimaldab ruumiandmete analüüsni ning laseb rasterfailidega töötada efektiivselt ja intuitiivselt. Käesolevas töös oli Rasterio peamiseks tööriist rasterandmete lugemiseks ja töötlemiseks, sealhulgas satelliidipiltide koostamiseks ja maskide genereerimiseks.

QGIS

QGIS on tasuta ja avatud lähtekoodiga töölaua GIS-tarkvara, mis võimaldab kasutajatel andmeid visuaalselt analüüsida, redigeerida ja kaardistada. See toetab mitmeid andmeformaate ja pakub laialdasi geoprotsessimise võimalusi, olles populaarne nii akadeemilises kui ka professionaalses keskkonnas. Käesolevas töös kasutatakse QGIS-i peamiselt andmete visualiseerimiseks ja analüüsimiseks, et mõista ruumiandmete struktuuri ja omadusi.

PostGIS

PostGIS on PostgreSQL andmebaasi laiendus, mis lisab ruumiandmete töötlemise funktsionaalsuse. See võimaldab keerukaid ruumi operatsioone ja on oluline tööriist suurte ruumiandmete kogude haldamisel ning analüüsил. Käesolevas töös autor ise otseselt PostGIS-i ei kasutanud, kuid Keskkonnaagentuuri andmebaas, kust andmed saadi, on PostGIS-i baasil üles ehitatud. Seega on see oluline komponent andmete haldamisel ja töötlemisel.

Riistvara

Uurimistöö läbiviimisel kasutati ülikooli AI-labori ressursse. Labor koosneb ühest peasõlmest, mis haldab teisi masinaid, ning alamsõlmedest, mis teostavad töid. Autor kasutas ai-lab-07 sõlme CPU-intensiivsete ülesannete, nagu andmekogumi koostamine, piltide töötlemine ja kompressioon, ning mitte sügav närvivõrkude mudelite treenimiseks nagu *Random Foresti*. Samas süvaõppे eksperimentide teostamiseks kasutati ai-lab-04 sõlme, mille GPU ja mälumaht võimaldasid keerukamate mudelite treenimist. Selline ressursside jaotus aitas töövoogu optimeerida ja tagada tööde sujuva teostuse vastavalt konkreetsetele arvutusvajadustele.

Sõlm	Protsessor	Mälu	GPU	GPU mälu
ai-lab-07	3960X 24-cores/48-threads	128 GB	NVidia 2080Ti	11 GB
ai-lab-04	3970X 32-cores/64-threads	128 GB	NVidia 3090	24 GB

Tabel 2. Kasutatud riistvara

3.2 Andmestiku loomine

Selles peatükis käsitletakse andmestiku loomise protsessi, sealhulgas andmete kogumist, töötlemist ja maskimist. Andmestiku loomine on oluline samm igauguste andmete analüüsimesel ja seda ka masinõppe projektide puhul. Andmete kvaliteet ja sobivus mõjutavad otseselt mudeli täpsust ja usaldusväärssust. Nagu muudes valdkondades kehtib ka informaatikas Pareto printsip, mille kohaselt 80% probleemidest tuleneb 20% põhjustest. Seega on andmestiku loomine ja töötlemine äärmiselt oluline etapp, mis võib määrata kogu projekti edasise käigu.

3.2.1 Raie piirkonna andmete kogumine

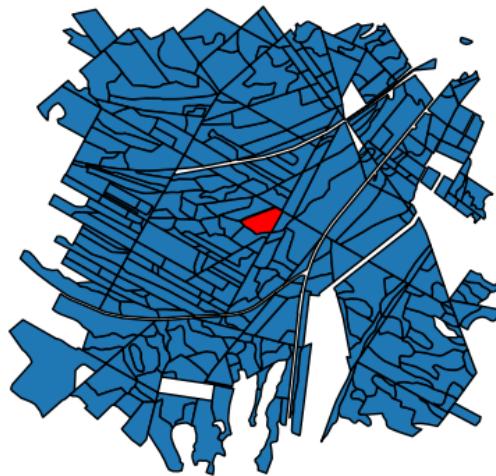
Metsateatis on dokument, mille kaudu metsaomanik esitab Keskkonnaametile kavandatavate raietööde või oluliste metsakahjustuste kohta teabe. Keskkonnaamet kontrollib esitatud teatiste nõuetekohasust ning veendub, et kavandatav raie vastab kehtivatele õigusaktidele. Metsateatised menetletakse ja säilitatakse riiklikus metsaregistris. Peale edukat menetlemist võib raietöödega alustada 10 päeva peale otsust ja kuni 24 kuu jooksul. [21] Metsateatised on avalikud ja neid saab vaadata riiklikus metsaregistris.

Metsade inventeerimise ja registrisse kandmise protsess algab metsaeraldiste täpse kaardistamisega, kasutades L-EST97 ristkoordinaatide süsteemi, Eesti põhikaarti, katastriüksuse plaane ning vajadusel kaugseire andmeid eraldiste piiritlemiseks ja võimalike situatsioonielementide täpsustamiseks. Kaardistamise tulemusena koostatakse geoinfosüsteemi metsaeraldiste kiht, kus iga eraldis on nummerdatud ning selle pindala, arvutatuna piiripunktide koordinaatide alusel, esitatakse hektarites vähemalt kümnendkohani ning täpsusega 10 meetrit — see loob aluse usaldusväärsele pindalaarvestusele ja edaspidistele takseerimistoimingutele. [22]

Koostöös Keskkonnaametiga (Envir) saadi andmed metsateatistest, mis sisaldavad teavet nii metsateatise esitamise kuupäeva, metsateatise menetlemise kuupäeva, metsateatise kehitivuse alguskuupäeva kui ka metsateatise kehtivuse lõppkuupäeva kohta. Kuna riigimetsade

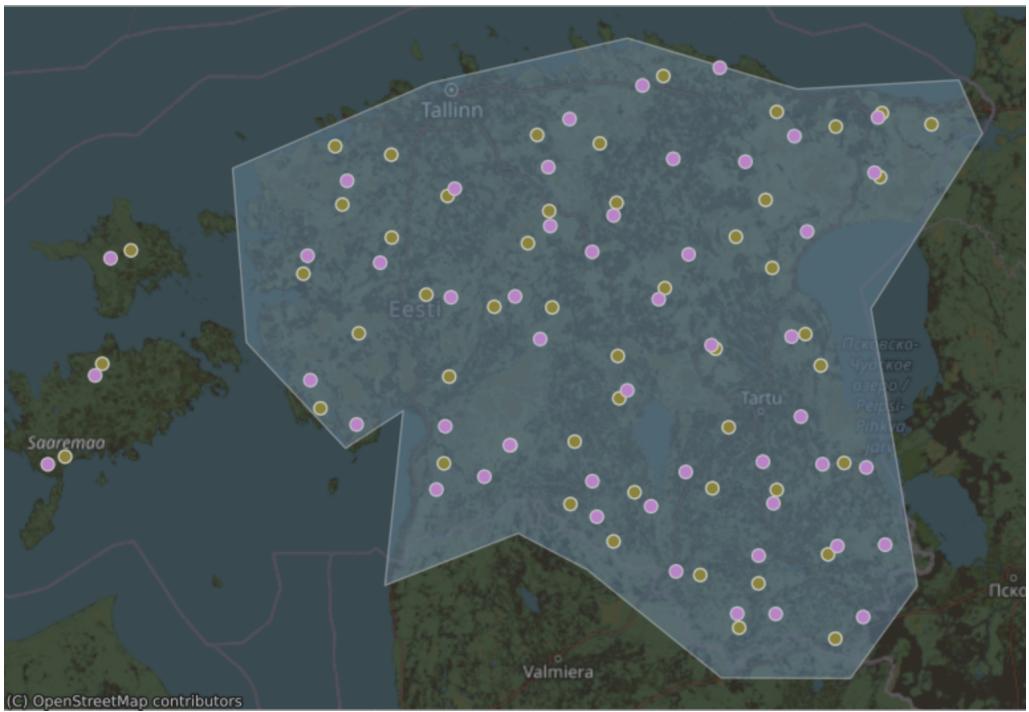
teatised on täpsemas seisukorras, siis võeti need raieteatised selle uurimustöö aluseks. Seoses sellega et ühe lõigu peal võib olla väga väike kogus metsa, sai teatiste pärimine ümber ehitatud sedasi, et ühe metsa raie ümber kogutakse peale raie toimumist kokku ka kõik teiste raiete raadiuses asuvad piirkonnad, millel on teada, kas on mets või raiuala. Piirkonniti pärimine sai teostatud kasutades PostGISi liidest Postgresi andmebaasiga. Iga raie sisaldab ka endas geomeetria veergu, mis esitab polügooni kujul selle asukohta.

Polügoon on geomeetriline kujund, mis määratleb kindla ala, ühendades üksteisega punktid, et moodustada suletud piirjoon. Andmetötluse ja ruumiandmete analüüsni kontekstis kasutatakse polügoone, et täpselt määratleda geograafilisi alasid. [23]

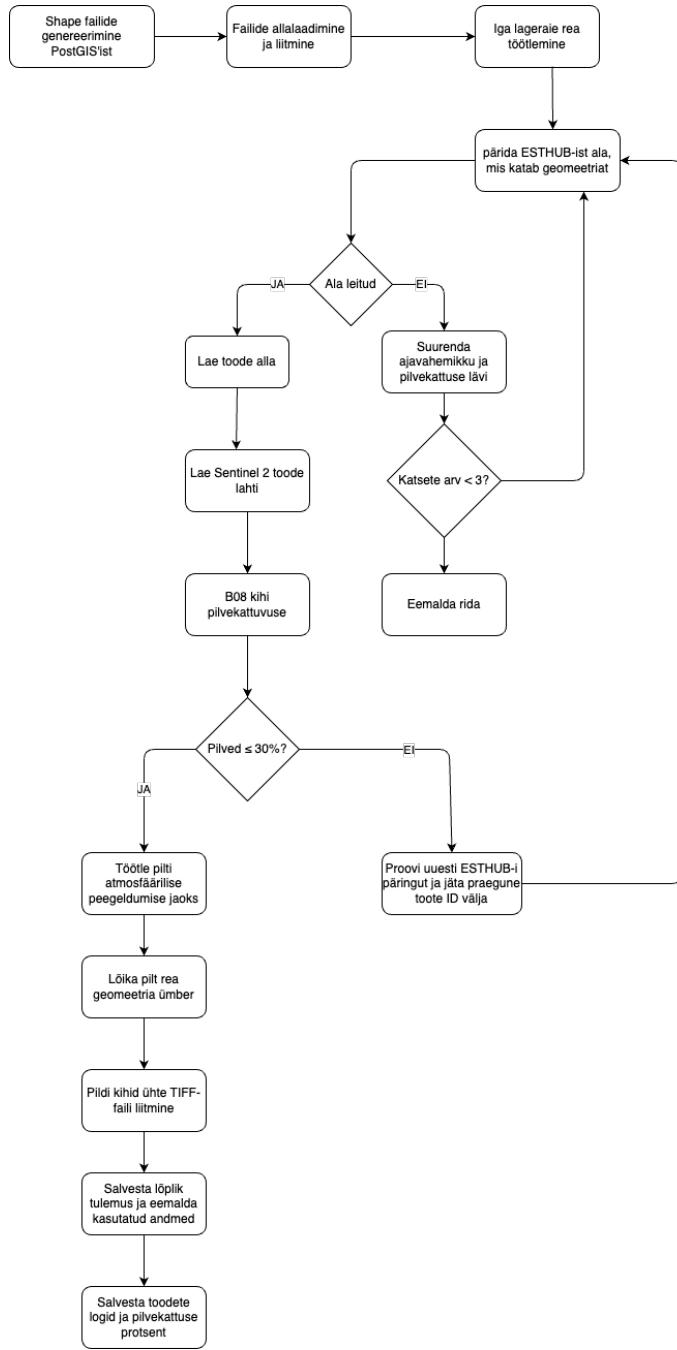


Joonis 2. Näidis ühe lageraie pärингust saadud ümbrus

Magistritöö peamiseks uurimisküsimuseks on, kas ja kuidas on võimalik kasutada väheseid näidete (*Few-Shot*) põhist alusmudelit. Selleks on aga vaja täpseid andmeid millelt õppida. Nagu eelnevalt mainitud siis metsaregistrist saadud andmed ei ole piisavalt täpsed, et neid otse kasutada. Seetõttu on vajalikud andmete täiendavat töötlemise ja maskimise etapid, kus andmed käiakse käsitsi läbi, kasutades registri andmeid maski põhjana. Ajalise piirangu tõttu pidi tegema alamvalimi. Et saada Eesti metsade kohta üldisemaid näiteid kasutati selleks KMeans klasterdamise meetodit, et jagada metsad omakorda kahte erinevasse klassi okas- ja lehtpuud. Eesmärgiks oli koguda kokku 100 raiet ja nende ümbrust, et luua piisavalt andmeid, mille pealt mudelit treenida.



Joonis 3. KMeans klasterdamise tulemus, 100 raie ümbrust leht- või okaspudega



Joonis 4. Andmestiku loomise töövoog

3.2.2 Raie piirkonna maskide loomine

Need sammud mis Liis teeb kui valideerib maske.

3.3 Alusmudeli ülevaade

Alustemudelid (*Foundation models*) on suuremahulistel andmekogudel ennastjuhendavalalt treenitud sügavad närvivõrgud, mis toimivad üldotstarbelise baasina mitmesuguste ma-

sinõppe ülesannete lahendamiseks. Erinevalt traditsioonilistest mudelitest, mis on välja töötatud konkreetse ülesande jaoks ja nõuavad eraldi treeningut, on alusmudelid eelnevalt ettevalmistatud laia valiku ülesannete sooritamiseks — alates loomulikust keele töölemisest ja tekstigeneratsionist kuni pildiklassifitseerimise ja vastuste genereerimiseni — ilma täiendava märgendatud õppematerjalita. Nende mudelite kohanemisvõime tuleneb nii suurest parameetrite hulgast kui ka enesekontrollil põhinevast õppestrategiast, mis võimaldab neid hõlpsasti peenhäälestada konkreetsete rakenduste jaoks. Võimalus keskenduda mudeli peenhäälestusele ja mitte nullist treenimisele omakorda vähendab oluliselt arendusaega ja arvutiressursside vajadust. [24]

3.3.1 CLIP ja selle kasutus

3.3.2 DINO v2 ja selle kasutus

Käesolev peatükk analüüsib DINO v2 mudeli võrdlust teiste tipptasemel mudelitega, eriti semantilise segmenteerimise kontekstis, ning põhjendab selle valikut metsaalade ja metsaraie tuvastamiseks satelliidipiltidel.

DINO v2 on Meta AI poolt loodud isejuhendatud (self-supervised) mudelite kogum, mille eesmärk on õppida üldotstarbelisi visuaalseid omadusi ilma märgendatud andmeteta. Mudel põhineb Vision Transformer (ViT) arhitektuuril, mille erinevad variandid (nt ViT-S/14, ViT-B/14, ViT-L/14 ja ViT-g/14) on eelõpetatud suurel, mitmekesise sisuga ja kureeritud pildikogumil. Mudeli struktuuri põhjaks on õpetaja–õpilase skeem, kus õpilasmudeli parameetreid koheldakse tavalise ViT-võrguna, aga õpetajamudeli kaale uuendatakse õpilase kaalude eksponentsialse libiseva keskmise kaudu. Treeningprotsessi stabiliseerimiseks ja tunnusruumi hajutamiseks on lisatud Kozachenko–Leonenko (KoLeo) regulaariaja, mis soodustab tunnuste ühtlast jaotust. Õppetöö lõpus suurendatakse sisendpiltide resolutsiooni ajutiselt 518×518 pikslile, et parandada piksli tasemel ülesannete, näiteks semantilise segmenteerimise ja objektivastuse ennustuse täpsust. Praktikas saavutab DINO v2 tänu optimeeritud FlashAttention-i ja PyTorch Full-Sharded Data Parallel (FSDP) meetodile kuni kahekordse kiiruse ning vajab kuni kolm korda vähem mälumahtu, võrreldes varasemate SSL-mudelitega. [25]

Ühes uuringus võrreldi DINO v2 mudelit mitmete teiste segmenteerimismeetoditega geoloogiliste kompuutertomograafia (KT) skaneeringute analüüsил. Hinnati Otsu lävendamist,

klastritehnikaid (K-keskmised, fuzzy C-means), juhendatud masinõppe meetodit (Random Forest) ja süvaõppe mudeliteid (UNet, ResNet152 ja DINOv2). Tulemused näitasid, et eelnevalt treenitud DINO v2 demonstreeris tugevat jõudlust kivimipiltide klassifitseerimisel isegi siis, kui KT-skaneeringud ei kuulunud selle esialgsesse treeningandmestikku. Segmenteerimise ülesannetes ületas eriti LoRA abil peenhäälestatud DINO v2 teisi meetodeid mitmeklassiliste ülesannete puhul, isegi piiratud andmetega. Visuaalne kontroll näitas, et DINO v2 poolt genereeritud segmenteerimismärgid olid sageli täpsemad kui algsed sihtmärgid. [26]

Teises uuringus hinnati DINO v2 jõudlust vasaku koja segmenteerimisel MRI piltidel. Eelnevalt treenitud DINO v2 saavutas Dice'i sarnasuse koefitsiendi (DSC) 87.1 %. Võrdluses nullist treenitud U-Net mudeliga näitasid tulemused, et iseseisev õpe DINO v2 abil võib oluliselt parandada meditsiinilise pildisegmenteerimine tõhusust ja täpsust, vähendades vajadust suurte märgistatud andmestike järele. [27]

Lisaks on Panopticon, DINO v2 raamistikule ehitatud mudel, saavutanud tipptasemel tulemusi GEO-Bench võrlustestis maakatte klassifitseerimisel, ületades teisi sensoragnostilisi mudeliteid ning näidates konkurentsivõimet ka kindlatele sensoritele kohandatud mudelitega. See demonstreerib DINO v2 arhitektuuri tugevust ja kohanemisvõimet erinevate kaugseire andmetüüpidega. [28]

Ühes teises töös võrreldi DINO (DINO v2 eelkäija) laiendust DINO-MC teiste iseseisvalt õppivate meetoditega kaugseire ülesannetes. Lineaarse testimise käigus saavutas DINO-MC 2.56% kõrgema täpsuse väiksema eelnevalt treenitud andmestikuga kui SeCo. Peenhäälestamisel kahel kaugseire klassifitseerimise ja muutuste tuvastamise ülesandel ületas DINO-MC nii DINO kui ka SeCo mudeliteid. [29]

Ülaltoodud näited illustreerivad DINO v2 mudeli tugevust ja mitmekülgust erinevates segmenteerimise ülesannetes, sealhulgas geoloogiliste, meditsiiniliste ja kaugseire piltide analüüsил. Mudeli võime saavutada konkurentsivõimelisi tulemusi ilma spetsiifilise peenhäälestuseta ning selle parem üldistusvõime muudavad selle sobivaks valikuks metsaalade ja metsaraie tuvastamiseks satelliidipiltidel.

3.3.3 SAM v2 ja selle kasutus

Segment Anything Model 2 (SAM 2) on pildi- ja videosegmentatsiooni ülesannete fundamentalne mudel, mis laiendab esmalt välja töötatud SAM-i (Kirillov et al., 2023 [30]) võimekust staatilistel piltildel ka ajaliselt dünaamilisele videomaterjalile. SAM 2 arhitektuur põhineb lihtsal transformeril, millel on integreeritud vooguv mälumoodul — see võimaldab reaalajas töödelda järjestikku sisenevaid kaadriseid ja säilitada informatsiooni sihtrühma objektist. Mälumoodul hoiab kuni N varasemat kaadrit ning M kasutajapõhist sisendkaadrit, mille alusel ennustatakse masklete’ e (masklet = objekti mask spatio-temporaalses ulatuses). [31]

SAM v2 põhistruktuur koosneb neljast põhimoodulist, mis töötavad järjestikku, et ühendada nii pildist tulenev informatsioon kui ka kasutajapoolne juhis ning ajaliselt varasemad tulemused. Esiteks võtab hierarhilise pildikodeerija sisse sisendkaadri ja teisendab selle mitme skaalaga omadusvektoriteks. Teiseks kodeerib prompt-moodul kasutaja märgitud punkte, kaste või maski, et mudel teaks, mida täpselt otsida. Kolmandaks lisab mälumoodul iga kaadri puhul salvestatud maski- ja pildiomadused FIFO-põhimõttel mälupanka, võimaldades modellel säilitada konteksti eelmistest kaadritest. Neljandaks rakendab transformer-põhine tähelepanumehhanism nii joooksva kaadri kui ka mälust saadud featuride vahelise suhluse, mille tulemuseks antakse maskidekooderile täpsed ruumilised vihed. Lõpuks dekodeerib maskidekooder paralelselt kõik saadud sisendid ning ennustab lõpliku objektimaski, mida mudel iteratiivselt uuendab ja talletab järgmiste kaadrite jaoks. Selline ülesehitus võimaldab SAM v2-l kiiresti ja tõhusalt segmenteerida nii staatilisi pilte kui ka videoid, säilitades minimaalse kasutajinteraktsiooni juures detailse täpsuse. SAM 2 rakendused katavad laia valikut domeene: meditsiiniline pilditöötlus, kaugseire ja satelliitpildi analüüs, liikumisskeeme segmenteerivad uuringud ning maskeeritud objektide tuvastamine. [31]

Artiklis „MPG-SAM 2: Adapting SAM 2 with Mask Priors and Global Context for Referring Video Object Segmentation“ kohandati SAM V2 mudelit viitematerjalidel põhinevaks videoobjektide segmentimiseks (RVOS). Teadlased lõid multimodaalse enkooderi, mis ühendas video- ja tekstipõhiseid tunnuseid, ning kasutasid maskide eelgeneratoreid globaalse konteksti kaardistamiseks. Uuenduslik hierarhilise ajalooline agregeerimismoodul võimaldas SAM 2-l säilitada objekti kontuure läbi videokaadrite, parandades ajaliselt järjepidevat segmentatsiooni. Katsetused mitmetel RVOS andmestikel näitasid märgatavat

täpsuse kasvu võrreldes varasemate meetoditega. [32]

Artiklis „SAM2 for abdomen: One-shot and no finetuning“ esitletakse SAM2 ja Emb-SAM meetodite kombinatsiooni, mis võimaldab kõhuelundite segmentatsiooni CT (*computed tomography*) kujutistel, kasutades ainult ühte märgistatud pilti. SAM2 kästleb järjestikuseid CT-vilusid kui videosarju ning propagatsioon toimub maskimälu kaudu. Emb-SAM täiendab protsessi, luues täpseid pseudo-märkeid iseenesliku õppimisega. Tulemused BTCV andmestikul näitavad tugevat segmentatsioonitäpsust, minimeerides käsitsi sekkumise vajadust. [33]

3.4 Seoste leidmine

Selleks et tõestada antud magistritöö eesmärki segmenteerida lageraie ja metsa alasid suurte visioonimudelitega, klusterdatakse DinoV2 väljundid, et leida, kas need alad on eristatavad. Selleks on vajalik eksperdigia valideerida ühe lageraie piirkonna alad, et kindel olla, et need vastavad tõele satelliidi pildilt.

Joonisel Joonis 5 on võetud näidiseks, et viia läbi eksperiment mõistmaks kas mudelid suudavad eristada lageraie ja metsa alasid satelliidi pildilt. Antud Sentinel-2 andmebaasist saadud pilt sai valitud esiteks sellepärast, et see on hea nähtavusega, võimalikult vähe pilvine ja soojemal hooajal, kui pole lund ja puud on lehteis. Teiseks on pilt heaks aluseks, sest sellel on sattunud raie- ja metsapiirkondi kõrvuti.



Joonis 5. Näidis sateliidi pilt

Joonisel Joonis 6 on näha lageraie piirkond, mis on toodud välja tumedama roosana, ja metsa piirkond, mis on joonisel heleroosana. Tegemist on aladega mis on teada Keskkonnaametile ja mille kohta on olemas ka metsateatis. Sateliidi pilt on saadud Sentinel-2 andmebaasist ja sellel on 10 meetriline resolutsioon. Antud pilt on saadud raie teostamise ajast kuni 40 päeva hiljem, seega on see piisavalt värske, et näha ka metsade seisukorda.



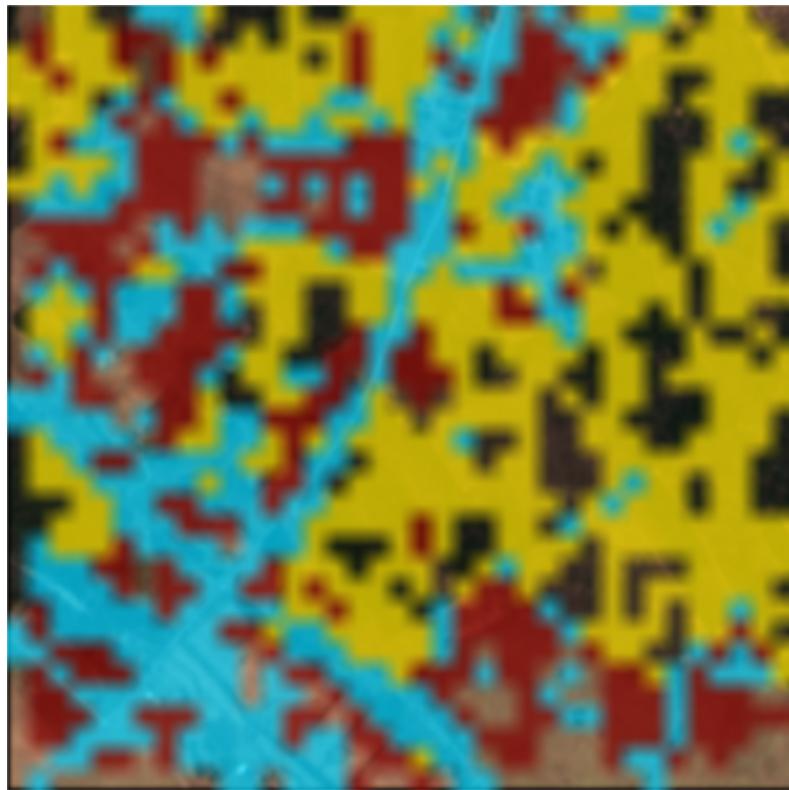
Joonis 6. Raie piirkonna mask sateliidi pildil

Joonisel Joonis 7 on näha lageraie piirkond, mis on toodud välja tumepunasena ja metsa piirkond, mis on märgitud rohelisega. Ekspert on võtnud teatistest saadud info aluseks, aga muud infot nagu aerofotod ja teised lainepike pildid on samuti kasutatud, et leida täpsemad piirded. Ekspert on leidnud, et antud piirkonnas on ka teisi alasid, mis ei ole lageraie, aga siiski on nad metsad. Samuti on pildil alasid, mis teatistes on märgitud metsaks aga silmaga vaadates kujutab rohkem raiet. Seega on eksperdi poolt loodud mask palju täpsem ja seetõttu on eksperdi kaasamine vajalik andmestiku loomise protsessis.



Joonis 7. Raie piirkonna mask eksperdi poolt korrigeeritud

Järgneval joonisel Joonis 8, rakendati klastrialüüsi süvaõppemudelist saadud kõrgdimensionaalsetele tunnusevektoritele, mis esindavad sisendpildi diskreetseid paiku. Eelkõige kasutati k-keskmise algoritmi, et grupeerida need tunnusevektorid sarnaste semantiliste omaduste alusel. Iga pildilaigule vastav tunnusevektor määrati ühte eelnevalt defineeritud arvu klastritesse, mille tulemusena saadi diskreetne klastermärgis iga pildipaiga jaoks. Seejärel visualiseeriti saadud klastermärgis pildil värvilise maskina, kus iga klaster on esitatud unikaalse värviga, võimaldades seeläbi kvalitatiivselt hinnata mudeli õpitud representatsioonide kohalikku sarnasust sisendpildil.



Joonis 8. Segmenteeritud näidis sateliidi pildist

Joonisel Joonis 9 on rakendatud klassipõhist klasterdamise meetodit, mille eesmärk on luua pildimaterjalist semantiliselt sidusaid piirkondi, grupeerides pildi elemendid eelnevalt defineeritud klassifikatsioonikategooriate alusel. Lähtudes mudeli genereeritud klassifikatsiooniväljunditest, määrratakse iga pildielement kõige tõenäolisemasse klassi, mille alusel moodustatakse klastrid. Selle meetodi rakendamise tulemusena saadakse segmentatsioon, kus ühte klastrisse kuuluvad pildi osad on mudeli poolt klassifitseeritud sarnaselt. Lõppesmärk on seeläbi genereerida pildist arusaadavam representatsioon, mis võimaldab interpreteerida pildi sisu semantilisel tasemel, tuues esile objektide ja piirkondade klassipõhised seosed. Pildil on väljatoodud klass 1 mis on mets ja klass 2 mis on lageraie, lisaks sai eemaldatud tausta klass, et oleks kergem jälgida uuritavaid klasse.



Joonis 9. T-SNE kluster analüüs DinoV2 mudeli väljunditest

klass 1 - mets, klass 2 - lageraie

Siit on näha, et lageraie ja mets on eristatavad ja annavad alust edasi uurida, mis alusmudelid suudavad paremini eristada lageraie ja metsa alasid.

3.5 Treenimis protsetuurid

4 Tulemuste analüüs

4.1 Tulemuste võrdlus

4.2 Edasiarendus ja täiustamine

5 Kokkuvõte

kokkuvõte

Kasutatud kirjandus

- [1] Loretta Cheung, Jonathan Mason ja Meaghan Parker-Forney. „Perimeter Defense: 4 Technologies for Detecting and Preventing Illegal Logging“ (Fri, 11/06/2015 - 11:16). URL: <https://www.wri.org/insights/perimeter-defense-4-technologies-detecting-and-preventing-illegal-logging> (vaadatud 01.03.2025).
- [2] *Tartu Ülikooli teadlased töötasid välja statistilised meetodid Eesti metsaressursi hindamiseks kaugseireandmete põhjal* | Tartu Ülikool. R, 11.09.2020 - 11:05. URL: <https://ut.ee/et/sisu/tartu-ulikooli-teadlased-tootasid-valja-statistilised-meetodid-eesti-metsaressursi-hindamiseks> (vaadatud 11.01.2025).
- [3] Maa-amet. *Riiklik satelliidiandmete keskus ESTHub*. URL: <https://geoportaal.maaamet.ee/est/ruumiandmed/riiklik-satelliidiandmete-keskus-esthub-p443.html> (vaadatud 26.02.2025).
- [4] *Infrastructure Overview* | Copernicus. URL: <https://www.copernicus.eu/en/about-copernicus/infrastructure-overview> (vaadatud 01.03.2025).
- [5] *Sentinel-2 - an Overview* | ScienceDirect Topics. URL: <https://www.sciencedirect.com/topics/earth-and-planetary-sciences/sentinel-2> (vaadatud 01.03.2025).
- [6] K. Isaienkov *et al.* „Deep Learning for Regular Change Detection in Ukrainian Forest Ecosystem with Sentinel-2“. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 14 (2021), lk. 364–376. doi: 10.1109/JSTARS.2020.3034186.
- [7] N.S. Podoprigorova *et al.* „Recognition of Forest Damage from Sentinel-2 Satellite Images Using U-Net, RandomForest and XGBoost“. Teoses: Proceedings of the 2024 6th International Youth Conference on Radio Electronics, Electrical and Power Engineering, REEPE 2024. 2024. doi: 10.1109/REEPE60449.2024.10479810.
- [8] *Intersection over Union (IoU): Definition, Calculation, Code*. URL: <https://www.v7labs.com/blog/intersection-over-union-guide> (vaadatud 26.02.2025).
- [9] *Understanding DICE COEFFICIENT*. URL: <https://kaggle.com/code/yerramvarun/understanding-dice-coefficient> (vaadatud 26.02.2025).
- [10] A. Karsenty. „Underlying Causes of the Rapid Expansion of Illegal Exploitation of Tropical Timber“. *International Forestry Review* 5.3 (1. september 2003), lk. 236–239. ISSN: 1465-5489. doi: 10.1505/IFOR.5.3.236.19136. URL: <http://www.ingentaconnect.com/content/10.1505/IFOR.5.3.236.19136> (vaadatud 04.03.2025).
- [11] *WWF - The Importance of Forests*. URL: https://wwf.panda.org/discover/our-focus/forests_practice/importance_forests/ (vaadatud 04.03.2025).

- [12] *About Copernicus | Copernicus*. URL: <https://www.copernicus.eu/en/about-copernicus> (vaadatud 04.03.2025).
- [13] Maa-amet. *National Satellite Data Centre ESTHub*. URL: <https://geoportaal.maaamet.ee/eng/spatial-data/national-satellite-data-centre-esthub-p654.html> (vaadatud 10.03.2025).
- [14] *SI Applications*. URL: <https://sentiwiki.copernicus.eu/web/s1-applications> (vaadatud 04.03.2025).
- [15] *S2 Applications*. URL: <https://sentiwiki.copernicus.eu/web/s2-applications> (vaadatud 04.03.2025).
- [16] *S3 Mission*. URL: <https://sentiwiki.copernicus.eu/web/s3-mission> (vaadatud 04.03.2025).
- [17] *S5P Applications*. URL: <https://sentiwiki.copernicus.eu/web/s5p-applications> (vaadatud 04.03.2025).
- [18] *S2 Mission*. URL: <https://sentiwiki.copernicus.eu/web/s2-mission> (vaadatud 25.03.2025).
- [19] *8. Coordinate Reference Systems — QGIS Documentation Documentation*. URL: https://docs.qgis.org/3.40/en/docs/gentle_gis_introduction/coordinate_reference_systems.html (vaadatud 26.03.2025).
- [20] Grant D. Pearse *et al.*, „Developing a Forest Description from Remote Sensing: Insights from New Zealand“. *Science of Remote Sensing* 11 (1. juuni 2025), lk. 100183. ISSN: 2666-0172. doi: 10.1016/j.srs.2024.100183. URL: <https://www.sciencedirect.com/science/article/pii/S2666017224000671> (vaadatud 06.04.2025).
- [21] *Metsateatis ja metsaregister | Keskonnaamet*. URL: <https://keskonnaamet.ee/elusloodus-looduskaitse/metsandus/metsateatis-ja-metsaregister> (vaadatud 02.04.2025).
- [22] *Metsa Korraldamise Juhend–Riigi Teataja*. URL: <https://www.riigiteataja.ee/akt/13124148?leiaKehtiv> (vaadatud 20.04.2025).
- [23] *What Is a Location Polygon?* URL: <https://www.narrative.io/knowledge-base/concepts/data-terms/what-is-a-location-polygon> (vaadatud 02.04.2025).
- [24] *What Are Foundation Models? - Foundation Models in Generative AI Explained - AWS*. Amazon Web Services, Inc. URL: <https://aws.amazon.com/what-is/foundation-models/> (vaadatud 19.04.2025).
- [25] Maxime Oquab *et al.* *DINOv2: Learning Robust Visual Features without Supervision*. 2. veebruar 2024. doi: 10.48550/arXiv.2304.07193. arXiv: 2304.07193 [cs]. URL: <http://arxiv.org/abs/2304.07193> (vaadatud 19.04.2025). Eelnevalt avaldatud.
- [26] *DINOv2 Rocks Geological Image Analysis: Classification, Segmentation, and Interpretability*. URL: <https://arxiv.org/html/2407.18100v3> (vaadatud 07.05.2025).

- [27] Bipasha Kundu *et al.* *Assessing the Performance of the DINov2 Self-supervised Learning Vision Transformer Model for the Segmentation of the Left Atrium from MRI Images*. 14. november 2024. doi: 10.48550/arXiv.2411.09598. arXiv: 2411.09598 [eess]. URL: <http://arxiv.org/abs/2411.09598> (vaadatud 07.05.2025). Eelnevalt avaldatud.
- [28] *Panopticon: Advancing Any-Sensor Foundation Models for Earth Observation*. URL: <https://arxiv.org/html/2503.10845v1> (vaadatud 07.05.2025).
- [29] *Extending Global-Local View Alignment for Self-Supervised Learning with Remote Sensing Imagery*. URL: <https://arxiv.org/html/2303.06670v2> (vaadatud 07.05.2025).
- [30] Alexander Kirillov *et al.* *Segment Anything*. 5. aprill 2023. doi: 10.48550/arXiv.2304.02643. arXiv: 2304.02643 [cs]. URL: <http://arxiv.org/abs/2304.02643> (vaadatud 17.05.2025). Eelnevalt avaldatud.
- [31] Nikhila Ravi *et al.* *SAM 2: Segment Anything in Images and Videos*. 28. oktoober 2024. doi: 10.48550/arXiv.2408.00714. arXiv: 2408.00714 [cs]. URL: <http://arxiv.org/abs/2408.00714> (vaadatud 16.05.2025). Eelnevalt avaldatud.
- [32] Fu Rong *et al.* *MPG-SAM 2: Adapting SAM 2 with Mask Priors and Global Context for Referring Video Object Segmentation*. 10. märts 2025. doi: 10.48550/arXiv.2501.13667. arXiv: 2501.13667 [cs]. URL: <http://arxiv.org/abs/2501.13667> (vaadatud 16.05.2025). Eelnevalt avaldatud.
- [33] Jongyun Hwang *et al.*, „SAM2 for Abdomen: One-shot and No Finetuning“. Teoses: *2024 9th International Conference on Intelligent Informatics and Biomedical Sciences (ICIIBMS)*. 2024 9th International Conference on Intelligent Informatics and Biomedical Sciences (ICIIBMS). Köide 9. November 2024, lk. 551–555. doi: 10.1109/ICIIBMS62405.2024.10792815. URL: <https://ieeexplore.ieee.org/document/10792815/> (vaadatud 16.05.2025).

Lisa 1 – Lihtlitsents lõputöö reproduutseerimiseks ja lõputöö üldsusele kättesaadavaks tegemiseks¹

Mina, Kristjan Luik

1. Annan Tallinna Tehnikaülikoolile tasuta loa (lihtlitsentsi) enda loodud teose “Metsaraie tuvastamine rakendades visiooni alusmudeleid”, mille juhendaja on Juhan-Peep Ernits
 - 1.1. reproduutseerimiseks lõputöö säilitamise ja elektroonse avaldamise eesmärgil, sh Tallinna Tehnikaülikooli raamatukogu digikogusse lisamise eesmärgil kuni autoriõiguse kehtivuse tähtaaja lõppemiseni;
 - 1.2. üldsusele kättesaadavaks tegemiseks Tallinna Tehnikaülikooli veebikeskkonna kaudu, sealhulgas Tallinna Tehnikaülikooli raamatukogu digikogu kaudu kuni autoriõiguse kehtivuse tähtaaja lõppemiseni.
2. Olen teadlik, et käesoleva lihtlitsentsi punktis 1 nimetatud õigused jäavat alles ka autorile.
3. Kinnitan, et lihtlitsentsi andmisega ei rikuta teiste isikute intellektuaalomandi ega isikuandmete kaitse seadusest ning muudest õigusaktidest tulenevaid õigusi.

17.05.2025

¹Lihtlitsents ei kehti juurdepääsupiirangu kehtivuse ajal vastavalt üliõpilase taotlusele lõputööle juurdepääsupiirangu kehtestamiseks, mis on allkirjastatud teaduskonna dekaani poolt, välja arvatud ülikooli õigus lõputööd reproduutseerida üksnes säilitamise eesmärgil. Kui lõputöö on loonud kaks või enam isikut oma ühise loomingulise tegevusega ning lõputöö kaas- või ühisautor(id) ei ole andnud lõputööd kaitsvale üliõpilasele kindlaksmääratud tähtajaks nõusolekut lõputöö reproduutseerimiseks ja avalikustamiseks vastavalt lihtlitsentsi punktidele 1.1. ja 1.2, siis lihtlitsents nimetatud tähtaaja jooksul ei kehti.